

Analysis of IoT Data in AWS Environment with ML Algorithms

İrem KÖMÜRCÜ
iremkomurcu.com
ikomurcu@deloitte.com



WHO AM I



Data Scientist @Deloitte



Google Developer Expert on ML



Computer Vision Lover!

ikomurcu@deloitte.com

iremkomurcu.com



iremkomurcu



irem-komurcu



iremkomurcubm



iremkomurcu

Bugün Ne Konuşacağız?

- Tahmine Dayalı Kalite
- IoT Servisleri ve AWS
- Uçtan uca Mimari Akış Oluşturma
- ML Yönetimi ve Sagemaker



Tahmine Dayalı Kalite

Üretim süreci verilerine dayalı olarak ürünle ilgili kaliteyi tahmin etmek ve sınıflandırmak için üretimde makine öğrenimi yöntemlerinin kullanılmasını içerir



**Kalite
Parametreleri**



**Kalite
Tahmini**



**Kalite
Sınıflandırması**

Gereksiz Kimyasal Atıkları Azaltan
Yıllık 300.000 \$'lık Tasarrufa Eşit
Önemli Bir Etki

Problem Neydi?

Tüketilen tutkal miktarı üretilen MDF için önemli bir kalite faktörü olduğu kadar önemli bir maliyet kalemidir.

MDF üreticisi, ürünleri için **optimum tutkal miktarını** kullanmak istiyor.

Sorun, laboratuvar testlerinin ortalama 6 saat sonra sonuçlanabilmesi nedeniyle, MDF üretim hattında kalite parametrelerini kalite ile ilgili müdahalede bulunabilecek kadar **hızlı ölçebilecek araçlardan yoksun** olmalarıdır.



Çözümde Hangi Adımları İzledik?

- MDF üretim hattı boyunca mekanik ve çevresel değişiklikleri izlemek için sensör verileri buluta taşındı
- İstatistiksel modellere dayalı sık kalite test sonucu tahminleri yapıldı
- Öngörülen kalite parametreleri kullanılarak MDF ürününün kalitesini en üst düzeye çıkarmak için optimum tutkal miktarı hesaplandı
- Gerçek zamanlı IoT verilerinin görselleştirilmesi, öneri bilgilerinin operatör tarafından takip edilen panolara yapıştırıldı




Sonuçlar ve Etkileri

- Tek kaynak kontrolü
- Kalite parametrelerini ölçmek için 4-6 saatlik testler beklemek yerine, hızlı reaksiyon ve üretim kalitesinde artış
- Hammadde tasarrufu, minimum yapıştırıcı ile maksimum kalitede üretim, gereksiz kimyasal israfını önleyerek üretimde karbon ayak izini azaltma
- İzlenebilir, okunabilir çıktılar (“Age of With”) üreterek operasyonel karar süreçlerini destekleme



Mimari Bileşenler



Projede Temel Adımlar

- Operasyon adımlarının belirlenmesi
- Kalite parametrelerine ve tutkal tüketimine etki eden etmenlerin tayini

- Ürün tipi bazında özelleştirilmiş kalite tahmin modellerinin geliştirilmesi
- Tutkal önerisi veren algoritmanın geliştirilmesi

**Fonksiyonel
Analiz**

**Veri
Analizi**

**ML ve
Optimizasyon**

**Model
Uygulaması**

- Üretim bandı sensör verilerinin analizi
- Laboratuvar sonuçlarının analizi
- Sensör verileri ve laboratuvar sonuçlarının veri olgunluğu analizi
- Modern bulut ve makine öğrenmesi operasyonu yöntemleri kullanılarak modelin sahaya uygulanması

Mimaride Genel Temel Noktalar

1.

ML Modeli

Belirli kalıp türlerini tanımak için eğitilmiş bir model

2.

Inference

Çıktıyı hesaplamak için canlı veri noktalarını bir ML modelinde çalıştırma işlemi

3.

Veri Alımı

Hemen kullanım veya bir veritabanında depolama için veri alma ve içe aktarma işlemi

4.

Model Eğitimi

Öğrenmek için eğitim verileri içeren bir makine öğrenimi algoritması sağlama

5.

Sagemaker

Makine öğrenimi modelleri oluşturup eğitmek ve ardından bunları doğrudan üretime hazır bir ortama dağıtmak için kullanılır

Mimari Bileşenler

1

IoT sensörlerinden gerçek zamanlı verinin AWS Cloud ortamına aktarılması

2

Aktarılan verilerin saklanması ve güvenliği

3

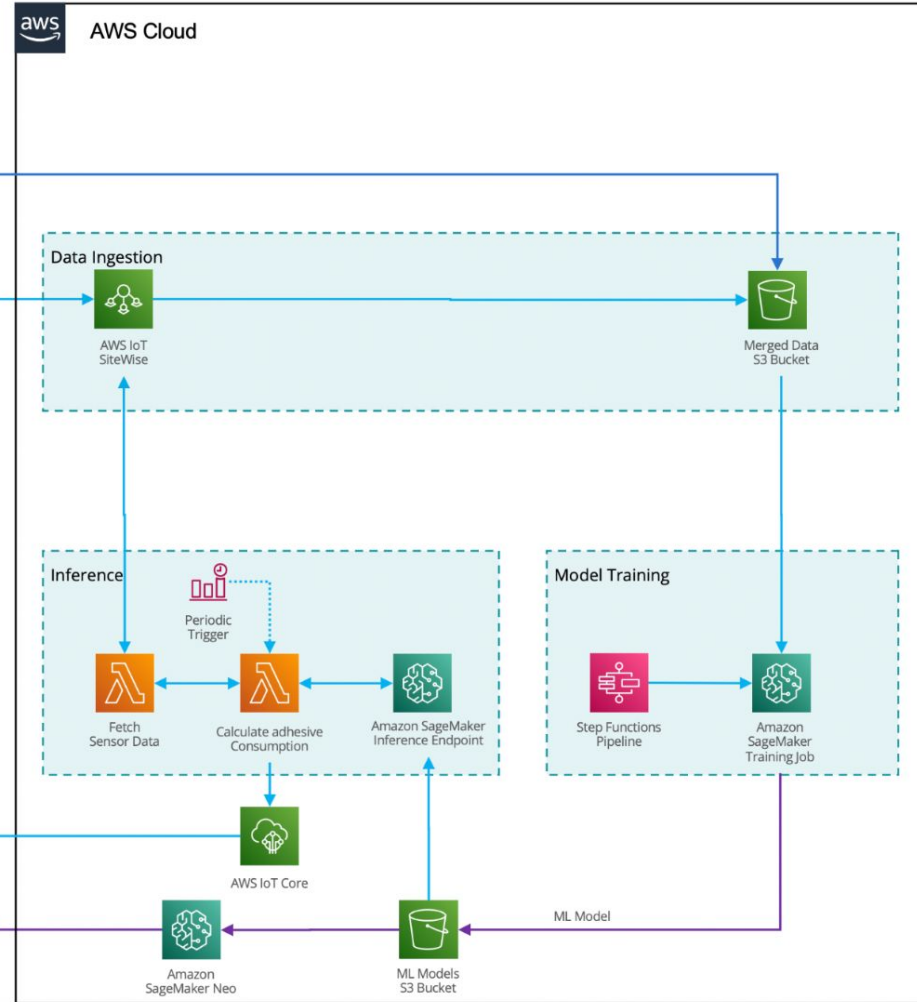
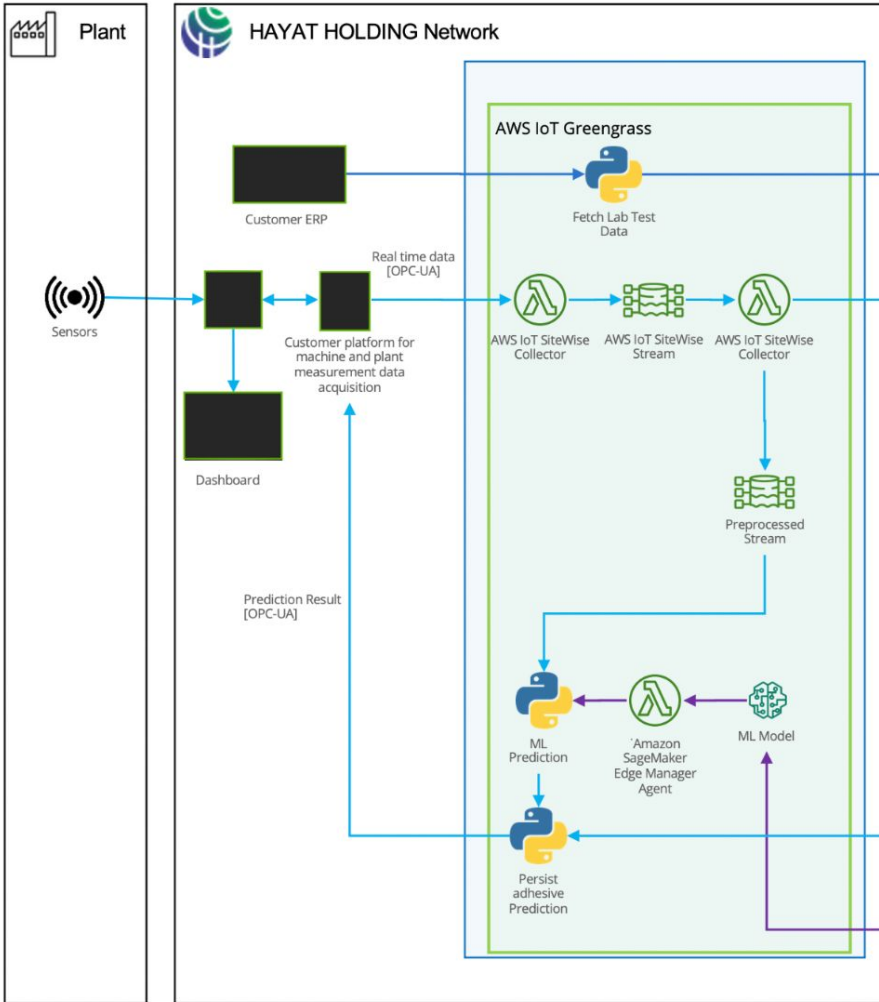
AWS Cloud ortamında Makine Öğrenmesi algoritmalarının çalışması

4

Gerçek zamanlı veri ile ML algoritmalarının optimizasyon ve sürekli geliştirilmesi

5

Model sonuçları ile fabrika ortamındaki arayüzün beslenmesi



Verideki son deęiřikliklere uyumlu
sonular arayze yansısın

Yeni veri otomatik olarak
veritabanına aktarısın

Srekli Geliřen

Deęiřime Ayak Uyduran

Utan uca geliřtirilebilir


Aktarılırken veri temizlięi
alıřmaları otomatik olarak
yapılsın

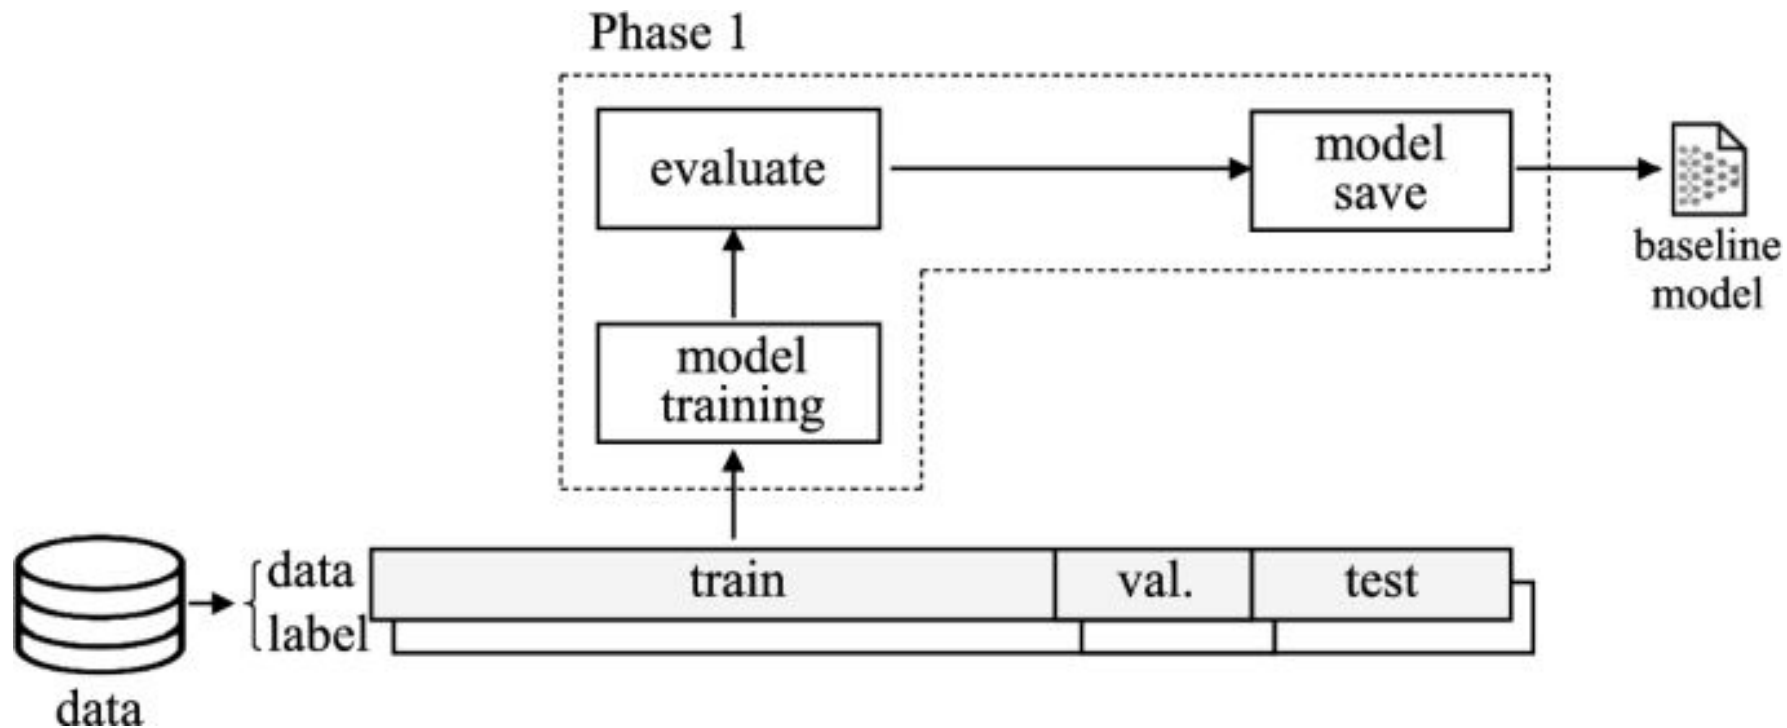
En geliřmiř model otomatik
olarak devreye alınsın

Makine ğrenmesi modeli dzenli
olarak verilerden ğrensin

Neden AWS Tercih Ettik?

- IoT Verilerini otomatik olarak ön işleyebilir, analiz edebilir ve raporlayabilir
- Bu verileri Amazon S3 veya Amazon Redshift gibi veri depolama hizmetlerine aktarabilirsiniz
- IoT cihazlarının gerçek zamanlı durumunu izleme olanağı
- Cihaz arızasında durum tespiti ve uyarı





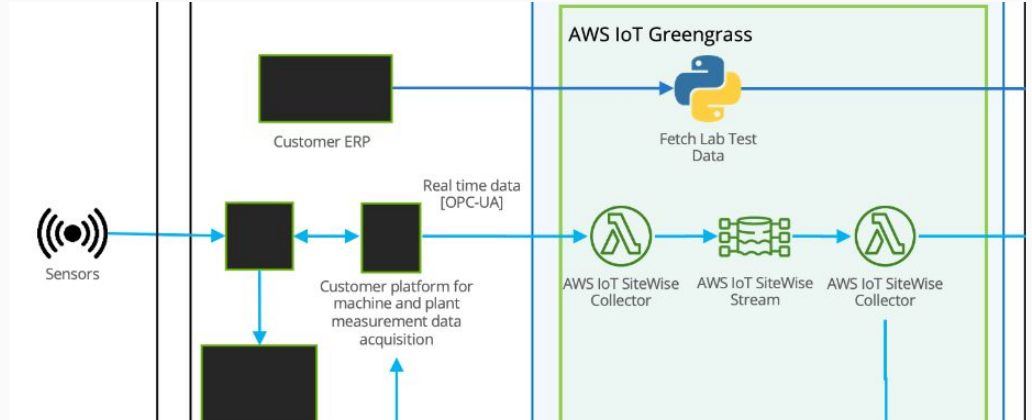
Veri Toplama

Sensör Verilerini Aktarma

Girdi verileri, AWS IoT Greengrass SiteWise Edge Gateway üzerinden aktarıldı. Toplamda **194 sensör** aktarıldı ve tahminlerin doğruluğunu artırmak için kullanıldı.


Sensör Verileri: Dakikada 1

Laboratuar Verileri: 8 saatte 1



Veri Kaynakları ve Veri Alımı

Sensör Verisi



Dakikada 1

- Tutkal
- Yonga verisi
- Basınç
- Kurutucu
- Katı Parafin

Laboratuvar Verisi




8 saatte 1

- Çekme direnci
- Kenar Vidalama
- Su Alma
- Kalınlık
- Elastikiyet
- Şişme

Veriler ve Ön İşlemler: PCA

Verilerin en önemli değişkenleri (principal component) belirlenerek, bu değişkenler üzerinden veri yeniden oluşturulur ve boyut azaltma işlemi gerçekleştirilir


- Toplam 194 sensör
- Ayrıntıya takılan bir model
- Az satır, çok sütun
- Noise endişesi
- High dimensional veri kaygısı



Veriler ve Ön İşlemler: Feature Engineering


Veri setindeki değişkenleri daha anlamlı ve etkili hale getirerek, makine öğrenmesi modelinin performansını artırmak için kullanılan bir veri ön işleme tekniğidir

- Değişkenlerin arasındaki ilişkiyi güçlendirmek
- Noise problemini ortadan kaldırmak
- Bazı özellikleri ön plana çıkartma/kaldırma



Model Eğitimi ve Optimizasyon

- Deep learning temelli model
- Multilayer perceptron
- Scorch: Scikit-learn ile kullanıma hazır PyTorch tabanlı kütüphane
- Optuna: Hiperparametre optimizasyonu için
- XGBoost
- Cross-validation



Model Sonucu ve Öneriler

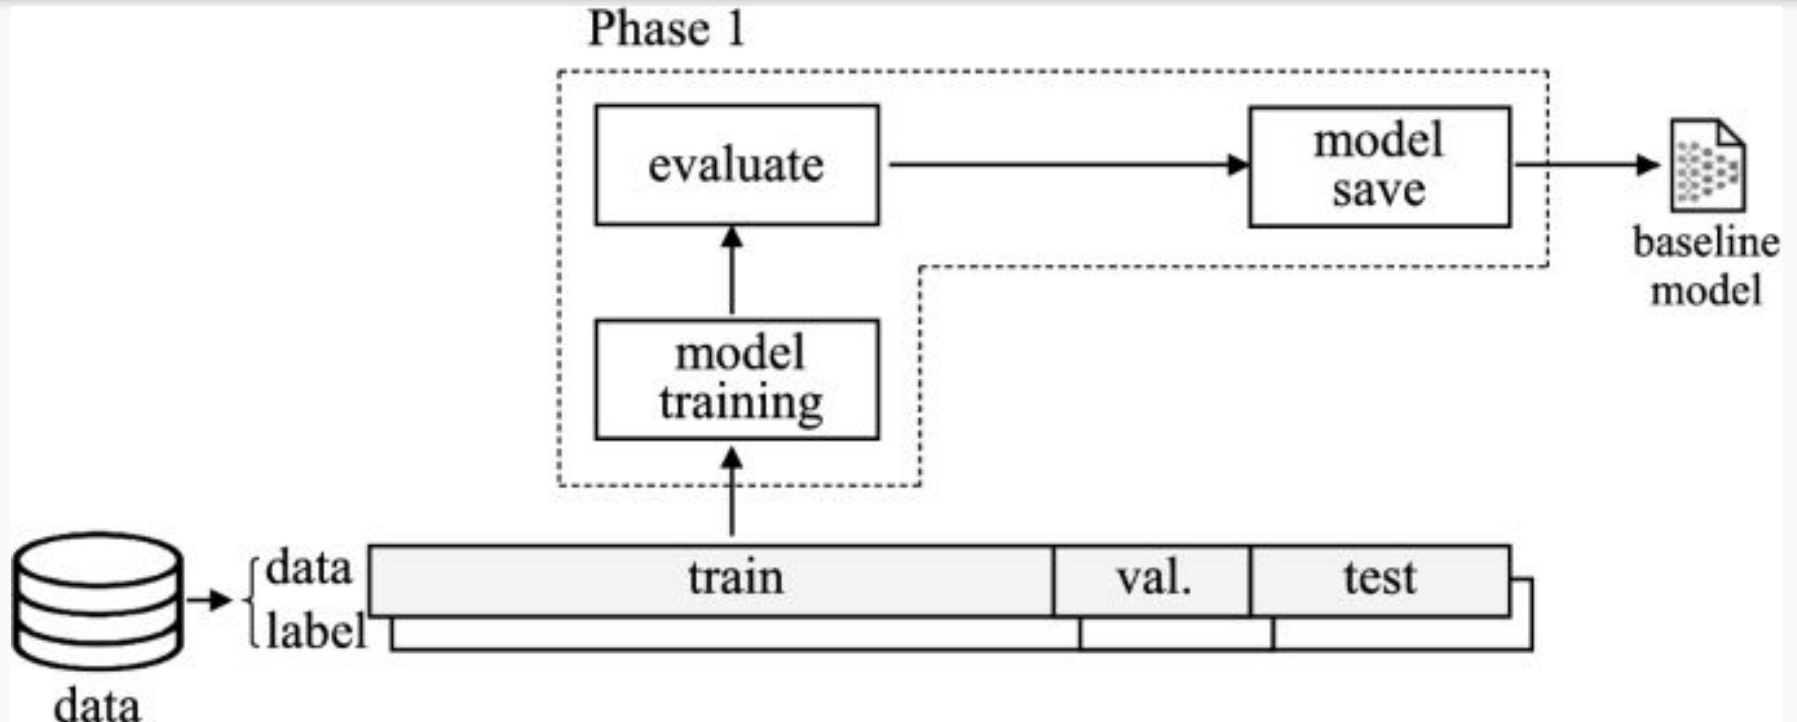
En büyük amaç tutkalı optimize etmek

- Sagemaker içi endpoint deploy
- Lambda ile endpoint isteği
- Model içi öğrenme

Optimizasyon

SageMaker otomatik model tuning ile model eğitimi ve optimizasyonu

Toparlayalım: Neden Sagemaker?



Sunuma Ulaşmak İçin Linkler

**GitHub
Repo**



**AWS
Blog**

Teşekkürler!

Herhangi bir soru var mı?



ikomurcu@deloitte.com

iremkomurcu.com



iremkomurcu



irem-komurcu



iremkomurcubm



iremkomurcu